

Backtest walk-forward de pair trading

Metodología y guía de interpretación de resultados

28 de julio de 2026

Índice

I	Metodología	3
1.	Idea general	3
2.	Universo de inversión	3
2.1.	Lista de tickers	3
2.2.	Reconstrucción histórica – el sesgo de supervivencia	3
3.	Datos	4
4.	Ventanas de tiempo	4
5.	Selección de pares (nivel trimestral)	4
5.1.	Liquidez	4
5.2.	Cointegración (Engle-Granger, 1987)	5
5.3.	Retest y estabilidad del β (70/30)	5
5.4.	Test de Chow (1960)	5
5.5.	Half-life (proceso de Ornstein-Uhlenbeck, 1930)	5
6.	Calibración in-sample	5
7.	Motor de señales operativo	6
8.	Control diario	6
8.1.	CUSUM (Brown, Durbin & Evans, 1975)	6
8.2.	CUSUMSQ – diagnóstico puro	6
8.3.	Chu-Stinchcombe-White (1996)	7
8.4.	ADF operativo	7
8.5.	Condición de cierre	7
9.	Motor de backtest	7
9.1.	Ventanas secuenciales con capital reciclado	7
9.2.	Reparto de capital entre pares	7
9.3.	Costos de transacción	8
II	Guía de interpretación de resultados	8

10.Estructura general del notebook	8
11.Las 3 tablas centrales	8
12.Métricas de riesgo por ventana	8
13.PNL, Flujo, MTM y Retorno acumulado	8
14.Retornos diarios sin acumular	9
15.CAPM	9
16.Bootstrap del PNL	10
17.Concentración del PNL y leave-one-out	10
18.Diagnóstico completo por par	10
19.CUSUM y deterioro gradual	10
20.Referencias	11

Parte I

Metodología

1. Idea general

La estrategia opera pares de acciones cuyo spread de precios es **estacionario** (revierte a una media), aunque los precios individuales no lo sean. Si dos acciones X e Y están *cointegradas*, existe una combinación lineal de sus precios (en logaritmos) que sí es estacionaria:

$$S_t = \ln(X_t) - \beta \ln(Y_t) \quad (1)$$

donde β es el coeficiente de cointegración. Cuando S_t se aleja de su media histórica más de lo normal, se apuesta a que revierta: se vende el activo “caro” relativo al otro y se compra el “barato”, cerrando la posición cuando el spread vuelve a su media.

Esto es *market-neutral* por construcción – no se apuesta a la dirección del mercado, sino a la relación relativa entre dos activos –, y es distinto del método de distancia clásico de pair trading (Gatev et al., 2006): acá el par se selecciona y valida por **cointegración estadística** (Vidyamurthy, 2004), no por distancia euclidiana de precios normalizados.

La implementación completa opera en 3 niveles de tiempo:

- **Trimestral**: selección del universo de pares y calibración del modelo (este documento).
- **Diario**: control de riesgo sobre el modelo ya calibrado – puede forzar el cierre de una posición.
- **Intradía (1h)**: generación de señales de entrada y salida sobre el spread ya calibrado.

Un principio de diseño que atraviesa todo el sistema: una vez calibrado el modelo de un par para una ventana operativa (β, μ, σ) , **no se re-estima durante esa ventana**. Todo el aparato de control diario existe justamente para detectar cuándo ese modelo congelado dejó de ser válido – no para ir ajustándolo sobre la marcha.

2. Universo de inversión

2.1. Lista de tickers

El universo candidato es el S&P 500. La lista de tickers se obtiene scrapeando la tabla de constituyentes actuales de Wikipedia (`universo_historico.py`).

2.2. Reconstrucción histórica – el sesgo de supervivencia

Un backtest que use la lista de tickers de *hoy* para simular años de historia pasada sufre **sesgo de supervivencia**: ignora que empresas que salieron del índice (quiebras, adquisiciones, reclasificaciones) también fueron parte del universo candidato en su momento, y que su ausencia del resultado final no es casual.

Para corregirlo, se reconstruye qué tickers estaban *realmente* en el índice en cada fecha pasada, deshaciendo los cambios documentados desde la lista de hoy hacia atrás:

$$\text{Universo}(t) = \text{Universo}(\text{hoy}) \ominus \{\text{cambios posteriores a } t\} \quad (2)$$

Concretamente: por cada cambio registrado (fecha, ticker agregado, ticker removido) posterior a la fecha objetivo, si fue una *alta* se saca ese ticker del universo (todavía no estaba); si fue una *baja* se lo vuelve a agregar (todavía no lo habían sacado). La fuente es la tabla “*Selected changes to the list of S&P 500 companies*” de la misma página de Wikipedia.

Nota: esta reconstrucción es una aproximación razonable para un backtest propio, no la fuente “gold standard” (proveedores point-in-time pagos como CRSP/Compustat). El registro de cambios de Wikipedia es confiable desde los 2000 en adelante, más disperso más atrás en el tiempo. Además, la limitación de fondo persiste: la descarga masiva de precios (yfinance) solo trae datos de tickers que cotizan hoy – si un ticker histórico ya salió del índice, va a faltar en los precios descargados aunque el universo reconstruido lo incluya correctamente. No hay relleno automático implementado todavía.

3. Datos

- **Diario:** hasta 5 años de historia, limitado únicamente por cuándo cada empresa salió a bolsa (no hay un tope artificial más corto en la fuente de datos usada).
- **Intradía (1h):** limitado a ~ 730 días (aproximadamente 2 años) *contados desde hoy*, sin importar qué rango se pida – este es un límite real y confirmado del proveedor de datos, no una elección de diseño.

Como el modelo de cada ventana necesita datos de **1h** tanto para la calibración (in-sample) como para el monitoreo (CSW), el horizonte total simulable del backtest queda acotado por ese límite de ~ 2 años de historia intradía – no por el diario, que alcanzaría para mucho más.

4. Ventanas de tiempo

Cada ciclo operativo se divide en 3 tramos:

Tramo	Duración típica	Función
Train	24 meses	Descubrir y validar pares candidatos (diario)
In-sample (IS)	6 meses	Calibrar μ , σ , $\sigma_{\text{día}}$ del spread (1h)
Out-of-sample (OOS)	~ 90 días	Operar de verdad – señales y control diario

El **IS** está contenido dentro del **train** (los últimos 6 de los 24 meses) – no es un tramo aparte de calendario. El **OOS** es estrictamente secuencial y no se solapa entre ventanas consecutivas – es la condición necesaria para poder reciclar capital de una ventana a la siguiente sin ambigüedad (no puede haber 2 ventanas operando el mismo capital al mismo tiempo). El **train** sí se solapa entre ventanas consecutivas, a propósito: en producción real, cada reconstrucción trimestral siempre mira los últimos 24 meses desde *hoy*, no encadena desde donde terminó el ciclo anterior.

5. Selección de pares (nivel trimestral)

Sobre el tramo de train (diario), se aplican en secuencia los siguientes filtros. Un par debe pasar **todos** para ser candidato operativo:

5.1. Liquidez

Se descarta el 30 % menos líquido (volumen en dólares promedio de 60 días) antes de buscar pares – evita seleccionar relaciones estadísticamente atractivas pero poco operables en la práctica.

5.2. Cointegración (Engle-Granger, 1987)

Para cada combinación de 2 tickers, se ajusta

$$\ln(X_t) = \alpha + \beta \ln(Y_t) + \varepsilon_t \quad (3)$$

por MCO, y se testea si el residuo ε_t es estacionario con el test de Dickey-Fuller aumentado (ADF, Dickey & Fuller, 1979). Se exige $p < 0,05$, $\beta > 0$ (evita relaciones inversas espurias), y el exponente de Hurst del spread reconstruido $< 0,35$ (confirma reversión a la media, no un camino aleatorio ni tendencial).

5.3. Retest y estabilidad del β (70/30)

El tramo de train se divide en 70%/30% cronológico. El par debe volver a cointegrar en el tramo del 30% final por separado, y el β estimado en ese tramo no puede diferir más de un 25% del β estimado en el 70% inicial – descarta pares cuya relación ya se estaba rompiendo silenciosamente durante el propio train.

5.4. Test de Chow (1960)

Contrasta si el modelo de cointegración es estructuralmente el mismo en ambos sub-tramos (70% vs. 30%) contra el modelo ajustado al tramo completo, vía un estadístico F:

$$F = \frac{(RSS_{\text{pool}} - (RSS_{70} + RSS_{30}))/k}{(RSS_{70} + RSS_{30})/(n_1 + n_2 - 2k)} \quad (4)$$

Se exige $0,001 < p < 0,05$ – lo suficientemente bajo para rechazar homogeneidad total, pero no tan bajo como para sospechar un quiebre real ya en marcha.

5.5. Half-life (proceso de Ornstein-Uhlenbeck, 1930)

Se ajusta un AR(1) al spread para estimar la velocidad de reversión:

$$\Delta S_t = \rho S_{t-1} + u_t, \quad \text{half-life} = \frac{-\ln(2)}{\ln(1 + \rho)} \quad (5)$$

Se exige que la reversión ocurra en un rango de días razonable (ni demasiado lenta – capital inmovilizado sin converger – ni demasiado rápida – ruido, no señal real).

6. Calibración in-sample

Con el par ya validado, se recalibra μ y σ del spread usando datos de **1h** del tramo in-sample (6 meses), anclados al primer precio de ese mismo tramo:

$$\mu = \overline{S^{\text{IS}}}, \quad \sigma = \text{std}(S^{\text{IS}}), \quad S_t = \ln\left(\frac{X_t}{X_0}\right) - \beta \ln\left(\frac{Y_t}{Y_0}\right) \quad (6)$$

donde X_0, Y_0 son los precios en el primer instante del in-sample. Este mismo ancla (X_0, Y_0) se reutiliza en todo lo demás – señales operativas y CSW – para que todo el sistema esté comparando contra el mismo punto de referencia.

También se calibra $\sigma_{\text{día}}$ (desviación estándar de los promedios diarios del spread respecto a μ) – insumo específico de CSW (Sección 8.3).

7. Motor de señales operativo

Sobre el spread OOS (1h), anclado al mismo (X_0, Y_0) del in-sample:

- **Entrada:** si $S_t > \mu + k\sigma$, se vende el spread (corto X , largo Y); si $S_t < \mu - k\sigma$, se compra el spread. Por defecto $k = 1$.
- **Salida por reversión:** se cierra cuando el spread cruza de vuelta μ .
- **Stop VaR- τ :** si el spread pasa τ velas consecutivas fuera de una banda más ancha $(\mu \pm 2k\sigma)$, se cierra por stop. τ se deriva de la half-life del par: $\tau = 7 \cdot \overline{\text{half-life}} \cdot 3$.
- **Take-profit / stop-loss:** umbrales sobre el retorno acumulado del ciclo de trading, deliberadamente “inertes” ($\pm 199,9\%$) en la configuración por defecto – no están pensados para disparar en operación normal.

La posición “plana” no es exposición cero: representa mantener ambas acciones en la proporción base $w_X = \frac{1}{\beta+1}$, $w_Y = \frac{\beta}{\beta+1}$ – una señal de *Sell/Buy* se mueve ± 1 unidad respecto a esa base, y un cierre vuelve exactamente a ella, no a exposición nula.

8. Control diario

Con el modelo ya congelado, 3 chequeos corren todos los días sobre el par (mientras tenga posición abierta), evaluando **solo con información disponible hasta ese día** (sin mirar al futuro). El cierre forzado se dispara cuando **las 3 condiciones coinciden simultáneamente** – ninguna por sí sola es suficiente.

8.1. CUSUM (Brown, Durbin & Evans, 1975)

Sobre el spread **diario**, se ajusta un modelo de regresión recursiva (*RecursiveLS*) que se re-estima con cada nueva observación, y se acumulan los residuos recursivos estandarizados:

$$W_t = \sum_{r=k+1}^t \frac{w_r}{\hat{\sigma}}, \quad w_r = \frac{y_r - \hat{y}_{r|r-1}}{\sqrt{1 + x_r'(X'_{r-1}X_{r-1})^{-1}x_r}} \quad (7)$$

Si W_t sale de su banda de confianza teórica, cuenta como “fuera de banda” ese día. Se exige una **racha de 7 días consecutivos** fuera de banda para contar como condición cumplida – un solo día de ruido no debería disparar nada.

Limitación conocida: por re-estimarse en cada paso, CUSUM “persigue” un deterioro *gradual* del par y nunca genera una sorpresa lo suficientemente grande como para salir de banda – queda estructuralmente ciego a ese modo de falla, aunque sí detecta bien saltos *abruptos* de un día para otro (ver Sección 19).

8.2. CUSUMSQ – diagnóstico puro

Acumula los residuos recursivos **al cuadrado**, normalizados – sensible a cambios de *varianza* más que de nivel. No decide ninguna acción por diseño (converge a 1.0 por construcción matemática hacia el final de cualquier muestra, lo que lo vuelve poco confiable como gatillo binario) – se calcula y se muestra únicamente como contexto adicional.

8.3. Chu-Stinchcombe-White (1996)

A diferencia de CUSUM, compara contra el modelo **congelado** (β, μ del in-sample), no uno que se re-ajusta. Sobre datos de **1h**, se acumula:

$$W(x) = \frac{1}{\hat{\sigma}\sqrt{n}} \sum_{i=n+1}^x (S_i - \mu), \quad b(x) = \sqrt{x(x-1) \left[\lambda^2 + \ln\left(\frac{x}{x-1}\right) \right]} \quad (8)$$

donde λ es un parámetro que controla el nivel de significancia global del monitoreo. Se usa $\lambda = 2,45$, **calibrado por simulación Monte Carlo propia** (no es un valor tabulado en la literatura original).

El disparo de CSW es un evento de una sola vez, no reevaluabile: la banda $b(x)$ está construida específicamente para que la probabilidad de que el camino *completo* $W(x)$ cruce esa banda en *algún* punto del horizonte de monitoreo quede acotada en el nivel de significancia elegido – es una probabilidad sobre el camino entero (análogo a un *stopping time* en análisis secuencial), no una prueba independiente repetida cada día. Por eso, una vez que **alerta_activa** se activa, **queda activa para siempre** dentro de esa ventana – no se resetea si el spread vuelve a comportarse bien después.

8.4. ADF operativo

Mismo test de Dickey-Fuller aumentado de la selección (Sección 5), pero corrido a diario sobre el spread del par **con posición abierta**, usando el β congelado (no uno reestimado). Se exige una racha de **5 días consecutivos** con $p\text{-value} > 0,10$ (evidencia de que el spread *dejó* de ser estacionario) para contar como condición cumplida.

8.5. Condición de cierre

$$\text{Cierre forzado} \iff \underbrace{\text{racha}_{\text{CUSUM}} \geq 7}_{\text{opcional, ver abajo}} \wedge \text{CSW activo} \wedge \text{racha}_{\text{ADF}} \geq 5 \quad (9)$$

El backtest permite además desactivar la exigencia de CUSUM (**requerir_cusum=False**) para aislar esta condición específica, pues con CSW+ADF ya podemos justificar cierres por sí solos – ver Sección 19.

9. Motor de backtest

9.1. Ventanas secuenciales con capital reciclado

El capital de la ventana N es el capital final de la ventana $N - 1$:

$$\text{Capital}_N = \text{Capital}_{N-1} + \text{PNL}_{N-1} \quad (10)$$

reflejando cómo se opera de verdad – no un monto fijo repetido en cada ciclo (a diferencia del backtest original de referencia, previo a esta versión con políticas de control).

9.2. Reparto de capital entre pares

Dentro de una ventana con varios pares válidos, el capital se reparte proporcional al valor inicial de cada par $V_0 = \frac{X_0 + \beta Y_0}{\beta + 1}$ – mismo criterio que usa producción real al crear una ventana operativa.

9.3. Costos de transacción

Se aplica un costo de 10 puntos básicos (0.10 %) sobre el valor nocional de cada cambio de posición.

Parte II

Guía de interpretación de resultados

10. Estructura general del notebook

El notebook recorre, en orden: universo histórico → descarga de precios → ventanas → backtest → métricas de riesgo (Sharpe, Drawdown) → análisis gráfico de PNL/Flujo/MTM/Retorno (consolidado, por ventana, por par) → CAPM (consolidado, por ventana, por par) → diagnóstico completo de un par de ejemplo por ventana.

Cada sección va de lo **consolidado** (todo el backtest junto) a lo **particular** (una ventana, un par) – primero la foto general, después el desglose.

11. Las 3 tablas centrales

- **df_resumen_ventanas**: una fila por ventana operativa – PNL, **capital_inicio**, **capital_fin**, **n_pares**, **n_cierres_forzados**. Es la fuente de la curva de capital “real”.
- **df_res_oos_total**: una fila por *barra de 1h* por cada par operado – contiene el spread, la señal de esa barra (*Buy/Sell/Close ...*), el motivo de cierre (**Exit_Reason**: *Mean Reversion*, *Stop VaR* τ , *Control diario*, *TP/SL*), y todas las columnas de valorización/PNL por barra. Es la fuente de todos los gráficos detallados.
- **df_pares_validos_total**: una fila por combinación par-ventana que pasó la selección (Sección 5) – β , p -value, half-life, Hurst, **score_selector**.

12. Métricas de riesgo por ventana

- **Sharpe**: retorno medio diario dividido por su desvío estándar. **Sharpe anualizado**: multiplicado por $\sqrt{252 \times 7}$ (252 días hábiles, 7 barras de 1h por día – coherente con la granularidad diaria de los retornos usados acá, no de la barra horaria).
- **Max Drawdown**: la mayor caída porcentual desde un máximo histórico de la curva de equity de esa ventana.
- **Calmar**: retorno final dividido por el valor absoluto del Max Drawdown – retorno obtenido por unidad de peor caída soportada.

Nota: con pocas ventanas (típicamente 6 en un backtest acotado a ~ 2 años de 1h), estas métricas tienen muestra chica – útiles como primera lectura, no como número definitivo.

13. PNL, Flujo, MTM y Retorno acumulado

Para cualquier subconjunto (cartera consolidada, una ventana, un par), el PNL diario se descompone en 2 fuentes independientes:

$$\text{PNL}_t = \underbrace{(\text{Valorización_Par}_t - \text{Valorización_Par}_{t-1})}_{\text{MTM - movimiento de precio}} + \underbrace{\text{Flujo}_t}_{\text{caja por ejecutar señales}} - \text{Costo}_t \quad (11)$$

- **PNL acumulado:** suma simple del PNL diario – el resultado total en dólares.
- **Flujo acumulado:** cuánta plata entró/salió por abrir y cerrar posiciones – típicamente negativo al abrir (compra) y positivo al cerrar (venta), o viceversa según el lado.
- **MTM acumulado:** cuánto cambió el valor de mercado de lo que ya se tenía en cartera, sin que hubiera ninguna ejecución ese día – la parte “pasiva” del resultado.
- **Retorno acumulado:** retorno diario compuesto ($\text{retorno}_t = \text{PNL}_t / \text{capital}_t$) vía log-retornos:

$$\text{Retorno_Acumulado}_T = \exp\left(\sum_{t=1}^T \ln(1 + \text{retorno}_t)\right) - 1 \quad (12)$$

- **Equity:** $1 + \text{Retorno_Acumulado}$ – curva de crecimiento con base 1.0.
- **Drawdown:** $\text{Equity}_t / \max_{s \leq t}(\text{Equity}_s) - 1$.

14. Retornos diarios sin acumular

Panel de serie de tiempo (retorno del día, sin acumular) más un histograma de esa misma distribución al lado. La curva acumulada esconde la varianza día a día, el agrupamiento de volatilidad y los valores atípicos puntuales – este gráfico los muestra directo.

Nota: en el nivel “por par” la muestra es chica (~60-90 días operativos por ventana) – el histograma sale escalonado, no una distribución suave. Es lo esperable con esa cantidad de datos, no un error.

15. CAPM

Para cada nivel (consolidado / por ventana / por par), se estima

$$R_i - R_f = \alpha + \beta_{\text{mercado}}(R_m - R_f) + \varepsilon \quad (13)$$

por MCO, contra el S&P 500 real (no un proxy inverso) y una tasa libre de riesgo (ETF de letras del tesoro de 3 meses).

- **Alpha:** retorno diario no explicado por el mercado – lo que en teoría debería aportar la estrategia *market-neutral* por sí sola.
- **Beta de mercado:** sensibilidad de la cartera al S&P 500. Cerca de 0 es lo esperable de una estrategia market-neutral bien construida; distinto de 0 sugiere exposición residual no cubierta.
- **R²:** cuánto de la varianza del retorno de la cartera explica el mercado – bajo es lo esperable acá (si fuera alto, la estrategia se estaría pareciendo a simplemente estar largo el índice).
- **p-value del Beta:** si es $< 0,05$, el Beta medido es estadísticamente distinguible de cero (barra coloreada en rojo en los gráficos de barras).

16. Bootstrap del PNL

Remuestrea con reemplazo las observaciones de PNL (por trade, o por par-día según la sección) miles de veces, para estimar un intervalo de confianza no paramétrico alrededor del PNL/retorno esperado, sin asumir una distribución teórica.

- **IC 95 %:** rango donde caería el PNL/retorno medio en el 95 % de los remuestreos. Si **no cruza cero**, es la evidencia más fuerte disponible en este backtest de que el resultado es distinguible de ruido puro.
- **Prob(PNL < 0):** fracción de los remuestreos que dieron resultado negativo – una lectura intuitiva del mismo intervalo.

Nota: con pocos trades/días, el bootstrap remuestrea de un conjunto chico – el intervalo sale ancho y algo escalonado, no una distribución suave. Mejor que nada, pero no hay que esperar precisión con muestra chica.

17. Concentración del PNL y leave-one-out

- **Gini del PNL positivo:** 0 = las ventanas ganadoras aportan por igual; 1 = una sola ventana concentra todo el resultado positivo.
- **Leave-one-out:** recalcula el PNL total sacando cada ventana, una a la vez. Si el resultado sigue siendo positivo al sacar *cualquier* ventana individual, el resultado es robusto – si depende de una ventana puntual, es frágil aunque el número consolidado se vea bien.

18. Diagnóstico completo por par

Para el primer par de cada ventana, a modo de ejemplo:

- **Spread in-sample + out-of-sample:** el spread completo (no solo el tramo operado), con las señales de apertura (*Buy/Sell*) y cierre marcadas – el color del cierre distingue si fue por reversión a la media o por control diario.
- **Relación de cointegración:** scatter de $\ln(X/X_0)$ contra $\ln(Y/Y_0)$, con la recta teórica ajustada en el in-sample. El in-sample se muestra en azul; el out-of-sample en un degradé (más oscuro = más viejo, más claro = más reciente) – si los puntos out-of-sample se despegan progresivamente de la recta, es evidencia visual directa de que la relación se está rompiendo.
- **CUSUM / CUSUMSQ / CSW:** los 3 caminos de estabilidad descritos en la Sección 8, con sus bandas.

19. CUSUM y deterioro gradual

La explicación es coherente con el diseño: al re-estimarse en cada paso, CUSUM absorbe un deterioro *gradual* sin generar nunca una sorpresa suficientemente grande – mientras que CSW y ADF, anclados al modelo congelado, sí acumulan la divergencia contra un punto de referencia fijo.

20. Referencias

- Brown, R. L., Durbin, J., & Evans, J. M. (1975). Techniques for testing the constancy of regression relationships over time. *Journal of the Royal Statistical Society: Series B*, 37(2), 149-163.
- Chow, G. C. (1960). Tests of equality between sets of coefficients in two linear regressions. *Econometrica*, 28(3), 591-605.
- Chu, C. S. J., Stinchcombe, M., & White, H. (1996). Monitoring structural change. *Econometrica*, 64(5), 1045-1065.
- Dickey, D. A., & Fuller, W. A. (1979). Distribution of the estimators for autoregressive time series with a unit root. *Journal of the American Statistical Association*, 74(366a), 427-431.
- Engle, R. F., & Granger, C. W. J. (1987). Co-integration and error correction: representation, estimation, and testing. *Econometrica*, 55(2), 251-276.
- Gatev, E., Goetzmann, W. N., & Rouwenhorst, K. G. (2006). Pairs trading: performance of a relative-value arbitrage rule. *Review of Financial Studies*, 19(3), 797-827.
- Hurst, H. E. (1951). Long-term storage capacity of reservoirs. *Transactions of the American Society of Civil Engineers*, 116(1), 770-799.
- Sharpe, W. F. (1964). Capital asset prices: a theory of market equilibrium under conditions of risk. *Journal of Finance*, 19(3), 425-442.
- Uhlenbeck, G. E., & Ornstein, L. S. (1930). On the theory of the Brownian motion. *Physical Review*, 36(5), 823.
- Vidyamurthy, G. (2004). *Pairs Trading: Quantitative Methods and Analysis*. Wiley.
- Zeileis, A., Leisch, F., Kleiber, C., & Hornik, K. (2005). Monitoring structural change in dynamic econometric models. *Journal of Applied Econometrics*, 20(1), 99-121.